A Aşaması — Açıklanabilir Yapay Zekâ Modellerinin Değerlendirilmesi

TEKNİK SUNUM HAZIRLIK KİTAPÇIĞI • SÜRÜM 1.0

Kapsam: Explainable Artificial Intelligence (XAI), SHAP, LIME, yerel ve küresel açıklamalar, Fidelity, Faithfulness, Stability, Consistency, açıklama maliyeti ve uygulamalı değerlendirme.

Bu konuyu yalnızca SHAP ve LIME algoritmalarını tanıtan bir sunum olarak değil, yapay zekâ modellerinin ürettiği açıklamaların ne kadar doğru, güvenilir, kararlı ve kullanışlı olduğunu bilimsel olarak değerlendiren bir çalışma şeklinde ele almanı öneriyorum.

Çünkü konunun en önemli ayrımı şu:

> Bir yapay zekâ modelinin açıklama üretmesi, o açıklamanın modelin gerçek tahmin davranışını doğru yansıttığı anlamına gelmez.

Hazırlayacağımız teknik sunumun merkezinde bu problem bulunacak.

ÖNERİLEN AKADEMİK SEVİYE: Lisansüstü / Teknik | 10 ana bölüm | 35–45 dakika sunum | 1 karşılaştırmalı deney

1. Müfredat ve öğrenme sıralaması

İçeriği 10 ana bölüme ayırdım. Her bölümün kendi alt konuları, öğrenme hedefleri, matematiksel derinliği ve sunumda kullanabileceğin çıktıları bulunuyor.

Bölüm	Konu ve kapsam	Öncelik
01	Açıklanabilir Yapay Zekâya giriş, problem tanımı, terminoloji	Temel
02	Açıklanabilirlik yaklaşımlarının sınıflandırılması	Temel
03	LIME: algoritma, matematik, örnek, sınırlılıklar	Çok yüksek
04	SHAP: Shapley değerleri, algoritma ve görselleştirme	Çok yüksek
05	Yerel ve küresel açıklamaların karşılaştırılması	Yüksek
06	Açıklama kalite metrikleri: Fidelity, Faithfulness, Stability, Consistency	Çok yüksek
07	Açıklanabilirlik yöntemlerinin sınırları ve güvenilirlik sorunları	Çok yüksek
08	Hesaplama karmaşıklığı, kaynak tüketimi ve ölçeklenebilirlik	Yüksek
09	Python ile uygulamalı SHAP–LIME karşılaştırması	Çok yüksek
10	Bulgular, akademik değerlendirme, sonuçlar ve gelecek çalışmalar	Yüksek

Kısım I — Kavramsal ve teorik altyapı

Bölüm 01 — Açıklanabilir Yapay Zekâ (XAI)

1.1. Açıklanabilir Yapay Zekâ nedir?

Açıklanabilir Yapay Zekâ (Explainable Artificial Intelligence — XAI), makine öğrenmesi modellerinin tahminlerinin veya karar davranışlarının insanlar tarafından incelenebilmesini sağlayan yöntem ve yaklaşımlar bütünüdür.

Klasik makine öğrenmesi değerlendirmesinde genellikle modelin ne kadar doğru tahmin yaptığı sorgulanır. XAI ise buna ek olarak modelin tahmininin hangi girdilerden, örüntülerden veya içsel hesaplamalardan etkilendiğini incelemeyi amaçlar.

Örneğin bir kredi risk modeli, müşterinin kredi geri ödememe olasılığını %72 olarak hesaplayabilir. Ancak yalnızca bu olasılığı bilmek, modelin kararını anlamak için yeterli değildir.

XAI ile şu sorular araştırılabilir:

• Gelir düzeyi tahmini hangi yönde etkiledi?

• Mevcut borç yükü tahminde ne kadar etkili oldu?

• Model yaş gibi hassas veya dolaylı ayrımcılığa yol açabilecek değişkenlere dayanıyor mu?

• Aynı müşterinin belirli özellikleri farklı olsaydı tahmin nasıl değişirdi?

Burada kritik nokta şudur: XAI yöntemleri çoğunlukla modelin tahmin davranışını açıklar; gerçek dünyadaki neden-sonuç ilişkilerini doğrudan kanıtlamaz.

1.2. Black-box (kara kutu) modeller

Kara kutu model, iç işleyişi doğrudan incelense bile karar davranışı insan açısından kolayca anlaşılamayan modeldir.

Örnekler arasında derin sinir ağları, büyük ensemble modelleri ve karmaşık gradient boosting sistemleri bulunur.

Bir makine öğrenmesi modelini genel olarak şu şekilde ifade edebiliriz:

$$f: X \to Y$$

Burada X özellik uzayını, Y tahmin uzayını ve f öğrenilmiş tahmin fonksiyonunu temsil eder.

Model bir x girdisinden f(x) tahmini üretir. Açıklama yöntemi ise model, girdi ve gerektiğinde arka plan verisini kullanarak bir açıklama oluşturur:

$$E(f, x) = e_x$$

e_x, örneğin özellik katkılarını gösteren bir vektör olabilir.

1.3. Interpretability ve Explainability farkı

Kavram	Anlamı	Örnek
Interpretability	Modelin işleyişinin doğrudan anlaşılabilmesi	Küçük bir karar ağacı
Explainability	Model davranışına ilişkin açıklama üretilebilmesi	Karmaşık bir modelin SHAP ile açıklanması
Transparency	Model yapısının, parametrelerinin veya işleyişinin erişilebilir olması	Açık model mimarisi
Post-hoc Explanation	Model eğitildikten sonra açıklama oluşturulması	LIME, SHAP

Bu kavramlar literatürde her zaman kesin sınırlarla kullanılmaz. Sunumda tanımlarını baştan belirlemek önemli olacaktır.

1.4. Açıklanabilirliğe neden ihtiyaç duyulur?

Gerekçeleri dört başlık altında ele alacağız: model hata ayıklama, güvenin uygun biçimde kalibre edilmesi, adalet ve önyargı analizi, kritik kararların denetlenebilirliği.

Örneğin tıbbi bir tahmin modelinin yüksek doğruluğa sahip olması tek başına yeterli değildir. Modelin hastalığı gerçekten klinik olarak anlamlı değişkenlerden mi, yoksa hastanenin kayıt sisteminden kaynaklanan yanıltıcı bir örüntüden mi öğrendiği de araştırılmalıdır.

Bölüm kazanımı: Model başarısı, model şeffaflığı ve açıklama kalitesinin birbirinden farklı kavramlar olduğunu açıklayabilmek.

Bölüm 02 — Açıklanabilirlik yöntemlerinin sınıflandırılması

2.1. Intrinsic ve Post-hoc yöntemler

Intrinsic interpretability, modelin kendi yapısından kaynaklanan anlaşılabilirliği ifade eder. Küçük karar ağaçları, seyrek doğrusal modeller ve belirli kural tabanlı sistemler buna örnektir.

Post-hoc explainability ise model eğitildikten sonra açıklama üreten yaklaşımları kapsar. SHAP ve LIME bu grubun önemli temsilcileridir.

2.2. Model-specific ve Model-agnostic yöntemler

Model-specific yöntemler belirli model mimarilerini kullanır. TreeSHAP ağaç modellerinin yapısından yararlanırken bazı gradient tabanlı yaklaşımlar diferansiyellenebilir modeller gerektirir.

Model-agnostic yöntemler modelin iç parametrelerine erişmeden, tahmin fonksiyonunu sorgulayarak açıklama oluşturabilir. LIME ve KernelSHAP buna örnektir.

2.3. Local ve Global Explanation

Yerel açıklama (Local): Tek bir tahminin yakın çevresindeki davranışı inceler.

Küresel açıklama (Global): Modelin veri kümesi genelindeki davranışını inceler.

Yerel açıklama belirli bir tahmin için "Bu sonuç neden üretildi?" sorusuna cevap arar. Küresel açıklama ise "Model genel olarak hangi özelliklerden ve ilişkilerden yararlanıyor?" sorusuna odaklanır.

2.4. Feature Attribution ve diğer yöntemler

Özellik atıf yöntemleri (feature attribution), tahmin üzerindeki katkıyı her bir özelliğe dağıtır. SHAP ve LIME çoğu tablosal kullanımda bu tür çıktılar üretir.

Ancak açıklanabilirlik yalnızca özellik öneminden ibaret değildir. Diğer yaklaşımlar arasında Partial Dependence Plot (PDP), Accumulated Local Effects (ALE), ICE, permutation importance, karşı-olgusal (counterfactual) açıklamalar ve Anchors bulunur. Bu yöntemlerin kapsamlı karşılaştırması için Molnar'ın Interpretable Machine Learning kaynağı uygundur.

Bölüm kazanımı: Bir XAI yönteminin hangi problemi çözdüğünü ve hangi açıklama kategorisine girdiğini belirleyebilmek.

Kısım II — SHAP ve LIME algoritmaları

Bölüm 03 — LIME: Local Interpretable Model-Agnostic Explanations

LIME, Ribeiro, Singh ve Guestrin tarafından 2016 yılında önerilen, karmaşık bir modelin belirli bir tahmin etrafındaki davranışını daha basit bir modelle yaklaşık olarak açıklayan yöntemdir.

3.1. Temel çalışma prensibi

LIME'ın temel fikri, tüm modeli açıklamaya çalışmak yerine tek bir örneğin çevresinde yorumlanabilir bir yaklaşım modeli (surrogate model) oluşturmaktır.

Örneğin Random Forest modelinin bir müşteriyi yüksek riskli sınıfına atadığını varsayalım. LIME bu müşterinin özellikleri çevresinde sentetik örnekler oluşturur, Random Forest'tan bu örnekler için tahmin alır ve tahminleri taklit eden ağırlıklı doğrusal bir model eğitir.

Bu basit modelin katsayıları, seçilen örneğin tahminine yönelik yerel açıklama olarak sunulur.

3.2. LIME algoritmasının adımları

1. Açıklanacak gözlemi seç: x_0 ve $f(x_0)$

2. Komşu örnekler üret: Perturbation / Sampling

3. Kara kutu modelden tahmin al: $f(z_i)$

4. Yakınlığa göre ağırlıklandır: $\pi_x(z_i)$

5. Basit açıklama modeli eğit: $g(z)$

6. Özellik katkılarını raporla: Local feature weights

3.3. LIME'ın matematiksel modeli

Orijinal LIME hedef fonksiyonu:

$$\xi(x) = \text{argmin} \, [\, L(f, g, \pi_x) + \Omega(g) \,] \, (g \in G)$$

Simge	Anlamı
f	Açıklanacak kara kutu model
g	Basit ve yorumlanabilir açıklama modeli
G	Açıklama modelleri ailesi
π_x	Açıklanacak gözleme göre yakınlık fonksiyonu
L	Yerel uyumsuzluk / kayıp fonksiyonu

Simge	Anlamı
Ω(g)	Açıklamanın karmaşıklık cezası

Bu optimizasyonda iki amaç dengelenir: açıklama modeli kara kutu modele yerel olarak benzemeli ve insan tarafından anlaşılabilecek kadar basit kalmalıdır.

3.4. Kernel ve komşuluk parametreleri

LIME çoğu uygulamada örnekleri yakınlıklarına göre ağırlıklandırır. Örnek bir kernel:

$$\pi_x(z) = \exp(-D(x,z)^2 / \sigma^2)$$

Burada D uzaklık ölçüsünü, σ ise komşuluğun etkili genişliğini belirler.

Kernel genişliği küçük olduğunda açıklama dar bir bölgeye odaklanır. Çok büyük olduğunda modelin daha geniş, potansiyel olarak doğrusal olmayan davranışını basit bir modelle temsil etmeye çalışır.

Bu parametre, açıklamanın hem fidelity hem de stability değerini etkileyebilir.

3.5. LIME'ın güçlü yönleri

LIME modelden bağımsız kullanılabilir, yerel yorumlaması kolaydır ve tablosal veri, metin veya görüntü için uyarlanabilir.

Bununla birlikte örnekleme rastlantısallığı, komşuluk tanımı, gerçekçi olmayan sentetik örnekler ve surrogate modelin yetersizliği önemli sorunlardır.

3.6. Bölümün uygulama örneği

Bir müşteri için risk skorunu etkileyen özelliklerin LIME ile çıkarılması, farklı random_state değerlerinde aynı açıklamanın ne kadar değiştiğinin incelenmesi ve komşuluk genişliğinin açıklamayı nasıl etkilediğinin görselleştirilmesi.

Bölüm kazanımı: LIME'ın neden yerel bir yaklaşım olduğunu, matematiksel optimizasyonunu ve açıklamalarının neden kararsız olabileceğini açıklayabilmek.

Bölüm 04 — SHAP: SHapley Additive exPlanations

SHAP, Lundberg ve Lee tarafından 2017 yılında önerilen, kooperatif oyun teorisindeki Shapley değerlerini makine öğrenmesi açıklamalarına uygulayan yöntem ailesidir.

4.1. SHAP'ın temel düşüncesi

Kooperatif oyun teorisinde oyuncular ortak bir kazanç üretir ve bu kazancın oyuncular arasında adil biçimde dağıtılması amaçlanır.

SHAP yaklaşımında oyuncular modelin özellikleri, kazanç ise açıklaması yapılan tahminin referans değere göre farkıdır.

Bu sayede SHAP, tahmin farkını özellik katkılarına ayırmayı amaçlar.

4.2. Shapley değerleri matematiği

$$\varphi_i = \Sigma \, [\ |S|!\ (M-|S|-1)!\ /\ M!\ ]\ [\ v(S \cup \{i\}) - v(S)\ ]$$

Burada F tüm özellikler kümesi, S özelliği içermeyen alt küme ve v(S) seçilen özellik koalisyonunun değerini tanımlayan fonksiyondur.

Bu formülün anlamı şudur: Bir özelliğin katkısı, farklı özellik kombinasyonlarına eklenmesinin yarattığı marjinal değişikliklerin ağırlıklı ortalamasıyla hesaplanır.

Önemli ayrıntı: v(S) fonksiyonunun nasıl tanımlandığı, özellik bağımlılıklarının nasıl ele alındığı ve hangi arka plan dağılımının kullanıldığı sonuçları değiştirebilir.

4.3. Additive explanation modeli

SHAP'ın en önemli özelliği, seçilen çıktı uzayında katkıların toplamsal biçimde ifade edilebilmesidir:

$$f(x) = \varphi_0 + \Sigma\, \varphi_i$$

Bu eşitlik, kullanılan SHAP açıklayıcısının toplamsallık varsayımları ve çıktı dönüşümü kapsamında yorumlanmalıdır. Örneğin bazı sınıflandırma modellerinde SHAP katkıları doğrudan olasılık değil, log-odds ölçeğinde hesaplanır.

4.4. Sayısal örnek

Tamamen öğretim amacıyla oluşturulmuş bir kredi riski örneği:

Özellik	Katkı
Referans risk skoru	0,30
Borç oranı	+0,28
Gecikmiş ödeme	+0,19
Gelir düzeyi	−0,05
Model tahmini	0,72

0,30 + 0,28 + 0,19 − 0,05 = 0,72. Değerler varsayımsaldır ve aynı çıktı ölçeğindedir.

Bu örnekte borç oranı ve gecikmiş ödeme risk tahminini artırırken gelir düzeyi azaltmaktadır. Ancak bu ifadeler model tahminine katkıyı anlatır; borç oranındaki bir müdahalenin gerçek dünyada aynı miktarda risk değişimi yaratacağını kanıtlamaz.

4.5. SHAP'ın kuramsal özellikleri

Temel Shapley yaklaşımında verimlilik, simetri, etkisiz oyuncu ve toplamsallık gibi oyun teorisi aksiyomları ele alınır. SHAP makalesi ayrıca additive feature attribution çerçevesinde local accuracy, missingness ve consistency özelliklerini tartışır.

Sunumda özellikle şu ayrımı yapmalıyız: SHAP'ın kuramsal consistency özelliği, farklı çalıştırmalarda açıklamanın aynı çıkması anlamındaki stability metriği değildir.

4.6. SHAP çeşitleri

Yöntem	Temel yaklaşım	Kullanım
KernelSHAP	Model-agnostic Shapley yaklaşımı	Genel modeller
TreeSHAP	Ağaç yapısını kullanan algoritma	Random Forest, XGBoost vb.
LinearSHAP	Doğrusal model yapısından yararlanma	Linear/Logistic modeller
DeepSHAP	Derin ağlar için yaklaşık katkı hesabı	Uyumlu sinir ağları
GradientSHAP	Gradient tabanlı yaklaşık atıf	Diferansiyellenebilir modeller

TreeSHAP'ın ağaç yapısından yararlanarak hızlandırılmış hesaplama yapması, yöntemler arası maliyet karşılaştırmasında önemli bir avantajdır. Ancak farklı özellik bağımlılığı varsayımları altında hesaplanan katkılar farklı yorumlara sahip olabilir.

4.7. SHAP görselleştirmeleri

Waterfall Plot: Tek bir tahminin katkılarla ayrıştırılması.

Beeswarm Plot: Birçok gözlemdeki katkı dağılımı.

Bar Plot: Ortalama mutlak katkıya göre özellik sıralaması.

Dependence Plot: Özellik değeri ile katkısının ilişkisi.

Bölüm kazanımı: Shapley değerinin matematiksel anlamını, SHAP'ın toplamsal yapısını, varyantlarını ve çıktı görsellerinin doğru yorumlanmasını kavramak.

Bölüm 05 — Yerel ve küresel açıklamaların karşılaştırılması

5.1. Yerel açıklamaların birleştirilmesi

LIME ve SHAP öncelikle örnek düzeyinde açıklamalar üreten yöntemler olarak ele alınabilir. SHAP değerleri çok sayıda örnek üzerinde birleştirildiğinde model davranışına ilişkin küresel özetler üretilebilir.

Örneğin bir özelliğin ortalama mutlak SHAP değeri:

$$I_j = (1 / N) \Sigma |\varphi_j^{(i)}|$$

Bu metrik, seçilen veri kümesindeki ortalama katkı büyüklüğünü gösterir. Ancak veri dağılımına bağımlıdır ve nedensel önem anlamına gelmez.

5.2. İki yaklaşım arasındaki fark

Boyut	Yerel	Küresel
Analiz birimi	Tek gözlem	Veri kümesi / model
Temel soru	Bu tahmin neden üretildi?	Model genel olarak nasıl davranıyor?
Örnek	LIME açıklaması	Mean absolute SHAP
Güçlü yön	Bireysel kararın incelenmesi	Model örüntülerinin tespiti
Risk	Yerel örnekleme duyarlılığı	Alt grup farklılıklarının gizlenmesi

5.3. Local-global contradiction

Bir özellik küresel düzeyde yüksek öneme sahip olsa da belirli bir tahminde düşük katkı gösterebilir. Bu tek başına açıklama tutarsızlığı değildir.

Örneğin yaş, kredi risk modelinde küresel olarak önemli olabilir; ancak belirli bir müşteride borçluluk ve ödeme geçmişi daha baskın olabilir.

Bölüm kazanımı: Küresel sıralamalar ile bireysel katkılar arasındaki farklılığı doğru yorumlayabilmek.

Kısım III — Açıklamaların kalite değerlendirmesi

Bölüm 06 — Açıklanabilirlik kalite metrikleri

Bu bölüm, sunumunun akademik ve teknik açıdan en önemli bölümünü oluşturuyor.

Bir sınıflandırma modeli için Accuracy, Precision, Recall ve F1-Score gibi metrikler hesaplanabilir. Ancak bunların hiçbiri doğrudan modelin ürettiği açıklamanın kaliteli olduğunu göstermez.

XAI açıklamalarının değerlendirilmesi daha karmaşıktır çünkü çoğu problemde elimizde doğru açıklamayı temsil eden bir ground truth bulunmaz.

Dolayısıyla açıklama kalitesini tek bir metrikle değerlendirmek yerine farklı boyutları birlikte incelemek gerekir. Quantus, bu değerlendirmeyi faithfulness, robustness, localization, complexity, randomization ve axiomatic metrics gibi kategoriler altında ele alır.

6.1. Fidelity — Açıklama modelinin asıl modeli temsil etme başarısı

Fidelity, özellikle surrogate model yaklaşımlarında, açıklama modelinin açıklanmaya çalışılan kara kutu modelin tahmin davranışını ne ölçüde taklit edebildiğini ölçer.

LIME için bu önemli bir değerlendirme ölçütüdür.

Asıl model f, açıklama modeli g olsun. Regresyon biçimindeki bir açıklama için örnek bir yerel fidelity ölçütü:

$$F_MSE(x) = 1 - [\Sigma\, w_i(f(z_i) - g(z_i))^2] \,/\, [\Sigma\, w_i(f(z_i) - \bar{f}w)^2]$$

Burada w_i komşuluk ağırlıkları ve $\bar{f}w$ ağırlıklı tahmin ortalamasıdır. Bu ifade ağırlıklı R^2 biçiminde bir uyum ölçüsüdür. Payda sıfır olduğunda özel durum ele alınmalıdır; ayrıca skor negatif olabilir.

Sınıflandırma için alternatif bir ölçü, yerel surrogate ve asıl modelin sınıf tahminleri arasındaki uyuşma oranıdır.

Örnek: LIME açıklama modelinin yakın komşulardaki davranışı iyi taklit etmesi yüksek yerel fidelity gösterebilir. Ancak bu, tüm veri kümesinde doğru bir açıklama olduğu anlamına gelmez.

6.2. Faithfulness — Açıklamanın model davranışına gerçekten bağlı olması

Faithfulness, açıklamanın önemli olarak gösterdiği özelliklerin modelin tahmin davranışını gerçekten etkileyip etkilemediğini değerlendirir.

Örneğin SHAP bir özellik için yüksek katkı hesaplıyorsa, uygun bir özellik müdahalesi veya perturbasyonu uygulandığında model tahmininde anlamlı değişim görülmesi beklenebilir.

Bir değerlendirme yaklaşımı, atıf büyüklükleri ile özelliklerin değiştirilmesi sonucundaki tahmin değişimlerini karşılaştırmaktır:

$$\text{Faithfulness} = \text{corr}(a_j, \Delta f_j)$$

Burada a_j özellik önemini, Δf_j ise belirli bir müdahale protokolüyle ölçülen model çıktı değişimini temsil eder. Korelasyonun yönü ve kullanılan değerlerin işaretli ya da mutlak olması açıkça belirtilmelidir.

Bu, faithfulness için mümkün ölçümlerden yalnızca biridir; evrensel tek bir formülü yoktur.

6.3. Fidelity ve Faithfulness farkı

Kriter	Fidelity	Faithfulness
Temel soru	Açıklama modeli asıl modelin davranışını taklit ediyor mu?	Açıklamada önemli görülen özellikler tahmin davranışını gerçekten yansıtıyor mu?
Tipik kullanım	Surrogate modeller	Özellik atıf yöntemleri
Örnek ölçüm	Yerel R^2, MSE, agreement	Feature perturbation, deletion, correlation
Yüksek değer	Yerel davranışa daha iyi uyum	Seçilen test altında daha güçlü davranışsal uyum

Literatürde bu iki kavramın bazen birbirinin yerine veya daha geniş anlamlarda kullanıldığını da belirtmeliyiz. Sunumda operasyonal tanımlarımızı sabitlemek karşılaştırmanın güvenilirliğini artıracaktır.

6.4. Stability — Açıklamanın kararlılığı

Stability, girdiye küçük ve anlamlı bir değişiklik uygulandığında açıklamanın ne kadar değiştiğiyle ilgilenir.

Örneğin benzer iki müşteriye model yaklaşık aynı risk skorunu veriyorsa, açıklamaların da belirli ölçüde benzer olması beklenebilir.

$$L_E(x) = \max [||E(x)-E(x')||_2 / ||x-x'||_2] (x' \in N\varepsilon(x))$$

Bu oran, açıklamadaki değişimin girdideki değişime oranını ölçer. Genellikle daha düşük değer daha yüksek yerel kararlılığa işaret eder.

Ancak bu yorumun geçerli olması için özelliklerin ölçeklenmesi, girdinin geçerli veri alanında kalması ve model çıktısının karşılaştırılabilir düzeyde sabit olması gerekir.

6.5. Repeatability — Aynı girdide tekrarlanabilirlik

Stability ile yakından ilişkili fakat ayrı ölçülmesi yararlı olan bir özellik, aynı model ve aynı veri üzerinde yöntemin tekrar çalıştırıldığında benzer açıklama üretmesidir.

Özellikle LIME için rastgele örnekleme sebebiyle farklı açıklamalar elde edilebilir.

$$V_j = Var(\varphi_j^{(1)}, \ldots, \varphi_j^{(R)})$$

Düşük varyans, aynı koşullarda daha yüksek tekrarlanabilirlik gösterir. Bunun açıklamanın doğru olduğunu tek başına kanıtlamadığını ayrıca vurgulamalıyız.

6.6. Consistency — Açıklama tutarlılığı

Consistency kavramı iki farklı bağlamda kullanılabilir:

Kuramsal SHAP consistency: Bir özelliğin marjinal katkısı model değişikliği sonrasında her özellik koalisyonunda azalmıyorsa, atanan Shapley değerinin de azalmaması beklenir. Bu, belirli varsayımlar altında sağlanan matematiksel bir özelliktir.

Ampirik açıklama tutarlılığı: Benzer gözlemlerde veya farklı açıklama yöntemlerinde özellik sıralamalarının ve katkı örüntülerinin ne ölçüde uyumlu olduğunu inceler.

İkinci durumda Spearman sıra korelasyonu veya Top-k Jaccard benzerliği kullanılabilir:

$$J(A,B) = |A \cap B| / |A \cup B|$$

Burada A ve B, iki açıklamada en önemli bulunan özellik kümeleridir.

Önemli ayrım: İki yöntem arasındaki yüksek uyuşma, iki açıklamanın da doğru olduğu anlamına gelmez.

6.7. Completeness / Local Accuracy

Özellikle toplamsal atıf yöntemlerinde, atıfların toplamının modelin açıklanan tahmin farkına eşit olup olmadığı test edilir.

$$\varepsilon_add = | f(x) - (\varphi_0 + \Sigma\varphi_i) |$$

Bu hata küçükse toplamsal yeniden oluşturma koşulu iyi sağlanmıştır. Ancak bu koşul açıklamanın nedensel veya davranışsal açıdan tamamen doğru olduğunu garanti etmez.

6.8. Complexity ve Interpretability

Bir açıklama matematiksel olarak doğru olsa bile çok sayıda özellik içerdiğinde insan tarafından anlaşılması zorlaşabilir.

Sıklıkla kullanılan karmaşıklık göstergeleri açıklamadaki sıfır olmayan özellik sayısı, sparsity, entropi veya kural uzunluğudur.

Az sayıda özelliğe dayalı açıklama genellikle daha okunabilir olsa da aşırı sadeleştirme model davranışını yanlış temsil edebilir.

6.9. Sanity Checks

Açıklama yönteminin gerçekten eğitilmiş modelin parametrelerine veya verinin öğrenilen örüntülerine duyarlı olup olmadığı test edilir.

Örneğin model ağırlıkları rastgeleleştirildiğinde üretilen açıklamalar hemen hemen aynı kalıyorsa, açıklamanın modele duyarlılığı konusunda şüphe oluşur.

Adebayo ve arkadaşlarının Sanity Checks for Saliency Maps çalışması, özellikle görsel olarak ikna edici açıklamaların teknik olarak geçerli olmayabileceğini göstermesi açısından önemlidir.

6.10. Metriklerin genel değerlendirme tablosu

Metrik	Ölçtüğü özellik	İdeal yön
Local Fidelity R^2	Yerel surrogate uyumu	Yüksek
Faithfulness Correlation	Atıf–tahmin davranışı ilişkisi	Yüksek
Deletion AUC	Önemli özelliklerin çıkarılmasına tepki	Protokole bağlı, genellikle düşük
Local Lipschitz	Perturbasyon duyarlılığı	Düşük
Repeated-run Variance	Tekrarlı açıklama değişkenliği	Düşük
Top-k Jaccard	Önemli özellik kümelerinin uyuşması	Yüksek
Additivity Error	Katkıların toplam hatası	Sıfıra yakın
Explanation Complexity	Açıklamanın büyüklüğü	Bağlama bağlı
Computation Time	Açıklama üretme süresi	Düşük

Bölüm kazanımı: Bir açıklama yöntemini yalnızca görsel çıktısına göre değil, çok boyutlu bir bilimsel değerlendirme çerçevesiyle ölçebilmek.

Kısım IV — Sınırlılıklar ve performans

Bölüm 07 — Açıklanabilirlik yöntemlerinin sınırlılıkları

7.1. Correlated Features problemi

Birbirleriyle güçlü ilişkili özellikler, modelin önem dağılımını yanıltıcı şekilde gösterebilir.

Örneğin aylık gelir ve yıllık gelir özelliklerinin aynı modelde bulunduğunu düşünelim. Bunlar yüksek ölçüde bağımlıdır. Kullanılan açıklama yöntemi ve özelliklerin yokluğu için seçilen varsayıma göre önem katkıları farklı dağıtılabilir.

7.2. Out-of-distribution perturbations

LIME veya SHAP'ın bazı yapılandırmaları veri dağılımında gerçekte bulunmayan özellik kombinasyonları üzerinden model tahminlerini sorgulayabilir.

Bu durumda yöntem modelin gerçekçi olmayan girdilere verdiği cevapları da açıklamaya katabilir.

Dolayısıyla açıklama hesaplaması için kullanılan arka plan verisi, örnekleme yöntemi ve bağımlılık varsayımları önemlidir.

7.3. Correlation ≠ Causation

SHAP değerinin yüksek olması, ilgili özelliğin gerçek dünyadaki sonucun nedeni olduğunu kanıtlamaz.

Özellik atfı ile nedensel çıkarım arasındaki fark sunumda özellikle vurgulanmalıdır.

7.4. Explanation disagreement

SHAP ve LIME aynı tahminde farklı özellikleri önemli gösterebilir. Bunun nedeni yöntemlerin farklı amaç fonksiyonlarına, referans dağılımlarına ve varsayımlara sahip olması olabilir.

Bu farklılık tek başına algoritmalardan birinin hatalı olduğunu kanıtlamaz. Ancak ek faithfulness ve stability testlerini gerekli kılar.

7.5. Kullanıcıya bağlı yorumlama sorunları

Bir açıklamanın anlaşılır olması, hedef kullanıcıya bağlıdır. Veri bilimci için yeterince açık olan bir waterfall plot, alan uzmanı olmayan biri için zor anlaşılabilir.

Bu nedenle açıklama kalitesi hem teknik hem de insan merkezli ölçütlerle ele alınmalıdır.

Bölüm 08 — Hesaplama maliyeti ve ölçeklenebilirlik

8.1. Özellik sayısının etkisi

Tam Shapley değerlerinin doğrudan hesaplanmasında özelliklerin tüm koalisyonlarının incelenmesi gerekir. M adet özellik için 2^M olası alt küme vardır.

Özellik sayısı	Koalisyon sayısı
4	16
8	256
12	4096
16	65536
20	1048576

Bu grafik, doğrudan tüm koalisyonları değerlendiren yaklaşımın neden yüksek özellik sayısında pahalı olabileceğini gösterir. Ancak bütün SHAP algoritmalarının bu sayıda model çağrısı yaptığı düşünülmemelidir.

8.2. Yöntemlere göre maliyet

Yöntem	Başlıca maliyet faktörü	Not
LIME	Üretilen komşu örnek sayısı, model çağrıları, surrogate eğitimi	Sampling maliyeti
KernelSHAP	Model sorguları, koalisyon örnekleme, ağırlıklı regresyon	Özellik sayısına duyarlı
TreeSHAP	Ağaç sayısı, derinlik ve yaprak yapısı	Ağaç yapısına özel hızlandırma
DeepSHAP	Ağ mimarisi ve referans örnekler	Model uyumluluğuna bağlı

8.3. Runtime ve Memory değerlendirmesi

Maliyet karşılaştırmasında yalnızca işlem süresine bakmak yeterli değildir. Aşağıdaki göstergeleri de değerlendireceğiz:

• Gözlem başına açıklama üretim süresi

• Toplam model tahmin çağrısı

• Peak RAM tüketimi

• CPU/GPU kullanımı

• İşlem süresinin örnek ve özellik sayısıyla ölçeklenmesi

8.4. Adil benchmark ilkeleri

Karşılaştırılan iki yöntem aynı veri kümesini, aynı modeli ve aynı hedef çıktıyı açıklamalıdır. Donanım ve yazılım ortamı kaydedilmeli; ısınma (warm-up), tekrarlı çalıştırmalar ve rassal tohumlar kontrol edilmelidir.

Ayrıca maliyet–kalite dengesi incelenmelidir. Daha hızlı bir yöntemin daha iyi açıklama ürettiğini veya daha pahalı bir yöntemin mutlaka daha faithful olduğunu varsayamayız.

Bölüm kazanımı: Açıklama algoritmalarının maliyetinin nereden kaynaklandığını, neden farklı ölçeklendiğini ve adil performans karşılaştırmasının nasıl yapılacağını açıklayabilmek.

Kısım V — Uygulama ve akademik değerlendirme

Bölüm 09 — Python ile SHAP ve LIME karşılaştırma uygulaması

Sunumun teorik kısmını desteklemek için küçük fakat bilimsel olarak savunulabilir bir karşılaştırma deneyi hazırlayacağız.

Projenin temel araştırma sorusu:

> Aynı makine öğrenmesi modeli ve aynı veri üzerinde SHAP ile LIME, açıklama doğruluğu, kararlılığı, tutarlılığı ve hesaplama maliyeti bakımından nasıl farklılaşmaktadır?

9.1. Önerilen deney mimarisi

Veri Kümesi: Breast Cancer Wisconsin (Diagnostic)

Makine Öğrenmesi Modeli: Random Forest Classifier

SHAP: TreeExplainer → Feature Attributions

LIME: LimeTabularExplainer → Feature Weights

Değerlendirme Katmanı: Fidelity / Faithfulness • Stability • Consistency • Runtime / Memory

Deney Sonuçları ve Karşılaştırmalı Grafikler

9.2. Kullanılacak teknolojiler

Teknoloji	Görevi
Python	Deneysel uygulama
NumPy / Pandas	Veri işleme
Scikit-learn	Veri kümesi, model ve değerlendirme
SHAP	Shapley tabanlı açıklamalar
LIME	Yerel surrogate açıklamaları
SciPy	Korelasyon ve istatistiksel hesaplamalar
Matplotlib	Grafik üretimi
Quantus	Uyumlu modellerde ek XAI kalite metrikleri
time.perf_counter	İşlem süresi ölçümü

Quantus'un değerlendirme metriklerinden yararlanılması sunumu araştırma düzeyinde güçlendirebilir. Ancak Quantus'un tüm metrikleri bütün modeller ve açıklama biçimleriyle doğrudan uyumlu değildir; seçilen kombinasyonlar önceden doğrulanmalıdır.

9.3. Deney 1 — Model eğitimi ve temel performans

İlk olarak veri kümesini eğitim ve test olarak ayıracağız. Random Forest modelini eğiteceğiz ve Accuracy, Precision, Recall, F1-Score ile ROC-AUC hesaplayacağız.

Bu aşamadaki amaç SHAP veya LIME'ı değerlendirmek değil, açıklayacağımız modelin tahmin performansını belgelemektir.

9.4. Deney 2 — Yerel açıklamalar

Test verisinden örnekler seçilecek ve her iki yöntemin aynı örneklere ürettiği açıklamalar incelenecek.

SHAP için waterfall plot, LIME için yerel özellik ağırlığı grafiği oluşturulacak. Her ikisi de aynı hedef sınıf çıktısını açıklayacak şekilde yapılandırılacak.

9.5. Deney 3 — Stability analizi

Seçilen test örnekleri üzerinde modelin tahminini fazla değiştirmeyen küçük perturbasyonlar oluşturacağız.

Her yöntem için orijinal açıklama ile perturbasyon sonrası açıklama arasındaki farkı hesaplayacağız.

Ayrıca LIME'ı farklı rassal tohumlarla tekrar çalıştırarak aynı girdideki tekrarlanabilirliği, girdiye karşı kararlılıktan ayrı olarak değerlendireceğiz.

9.6. Deney 4 — Faithfulness analizi

Her açıklama yönteminin en önemli bulduğu özellikleri, tanımlanmış bir müdahale protokolü kullanarak değiştireceğiz.

Ardından modelin ilgili sınıfa verdiği tahmin skorunun nasıl değiştiğini ölçüp deletion curve veya uygun bir faithfulness korelasyonu oluşturacağız.

Özellik silme işleminin gerçekçi olmayan veri kombinasyonları oluşturabileceği de deneyin sınırlılığı olarak raporlanacak.

9.7. Deney 5 — Açıklama tutarlılığı

SHAP ve LIME için en önemli ilk 5 özelliği karşılaştıracağız.

İki yöntemin feature ranking sonuçlarına Top-5 Jaccard Similarity ve uygun olduğunda Spearman korelasyonu uygulayacağız.

LIME'ın aralıklandırılmış özelliklerini orijinal özelliklerle doğru eşlememiz, aynı hedef çıktıyı değerlendirmemiz ve mutlak katkı sıralaması kullanıp kullanmadığımızı açıkça belirtmemiz gerekiyor.

9.8. Deney 6 — Hesaplama maliyeti

Her yöntemin açıklama üretim süresi aynı donanım ve örnek grubu üzerinde ölçülecek.

Ek olarak farklı örnekleme bütçelerinin kalite ve hız üzerindeki etkisi karşılaştırılacak. Bu deney, farklı bütçelerde maliyet–açıklama kalitesi ödünleşimini incelememizi sağlayacak.

9.9. Sonuç tablosu şablonu

Aşağıdaki tablo deneylerin sonunda gerçek ölçüm sonuçlarıyla doldurulacak. Henüz herhangi bir benchmark yapılmadığından sayısal değer vermiyoruz.

Değerlendirme	SHAP	LIME
Fidelity / uygunluk skoru	Ölçülecek	Ölçülecek
Faithfulness Correlation	Ölçülecek	Ölçülecek
Stability (Lipschitz)	Ölçülecek	Ölçülecek
Repeatability	Ölçülecek	Ölçülecek
Top-5 Agreement	Karşılıklı	Karşılıklı
Ortalama süre (ms)	Ölçülecek	Ölçülecek
Peak RAM (MB)	Ölçülecek	Ölçülecek

Bunun yanında confidence interval, örnek sayısı, standart sapma ve deney parametrelerinin de raporlanmasını öneriyorum.

9.10. Uygulama kazanımı

Bu bölümün sonunda yalnızca SHAP ve LIME grafiklerini gösteren bir Jupyter Notebook değil, yöntemleri ölçülebilir kriterlerle karşılaştıran, yeniden üretilebilir bir deney hazırlamış olacağız.

Bölüm 10 — Akademik tartışma ve sonuç

Bu bölümde deneylerden elde edilen bulguları araştırma sorularıyla ilişkilendireceğiz.

10.1. Temel araştırma soruları

1. SHAP ve LIME aynı tahmin üzerinde benzer açıklamalar üretiyor mu?

2. Daha yüksek yerel fidelity, daha yüksek faithfulness anlamına geliyor mu?

3. Küçük girdi değişiklikleri hangi yöntemin açıklamalarını daha fazla etkiliyor?

4. Farklı örnekleme bütçeleri LIME’ın kararlılığını nasıl değiştiriyor?

5. Hesaplama maliyeti ile açıklama kalitesi arasında nasıl bir ilişki var?

6. Özellik bağımlılığı ve veri dağılımı iki yöntemin sonuçlarını nasıl etkiliyor?

10.2. Bulguların yorumlanması

Tek bir yöntemi bütün senaryolarda en iyi ilan etmek yerine, yöntemin hangi model, veri türü ve değerlendirme hedefi altında avantaj sağladığını araştırmalıyız.

Örneğin TreeSHAP'ın belirli bir Random Forest modelinde KernelSHAP'tan hızlı olması beklenebilir. Ancak bu sonuçtan tüm SHAP yöntemlerinin tüm LIME yapılandırmalarından daha hızlı olduğu çıkarılamaz.

Benzer şekilde, LIME'ın bir örnekte yüksek yerel fidelity elde etmesi onun diğer örneklerde daha kararlı veya daha faithful olacağını garanti etmez.

10.3. Gelecek araştırmalar

Sunumun son teknik kısmında bu konuyu daha geniş araştırmalara bağlayabiliriz: nedensel XAI, counterfactual explanations, açıklama belirsizliğinin ölçülmesi, fairness-aware XAI ve büyük dil modellerinde açıklamaların faithfulness problemi.

Bu başlıklar sunumun merkezini dağıtmadan, konunun güncel araştırma önemini gösterecek.

Çalışma planı ve bölüm kontrol listesi

A aşamasını tamamladığında aşağıdaki kazanımların her birini örnek ve formülle açıklayabiliyor olmanı hedefliyoruz.

☐ XAI, interpretability ve explainability farkını açıklayabiliyorum. — Bölüm 01

☐ Intrinsic/post-hoc ve local/global yöntemleri sınıflandırabiliyorum. — Bölüm 02

☐ LIME'ın komşuluk örneklemesi ve amaç fonksiyonunu yorumlayabiliyorum. — Bölüm 03

☐ SHAP'ın Shapley formülünü ve temel varsayımlarını açıklayabiliyorum. — Bölüm 04

☐ Yerel ve küresel açıklama grafiklerini yorumlayabiliyorum. — Bölüm 05

☐ Fidelity ile Faithfulness farkını açıklayabiliyorum. — Bölüm 06

☐ Stability, repeatability ve consistency metriklerini ayırabiliyorum. — Bölüm 06

☐ Özellik korelasyonu ve dağılım dışı örnek sorunlarını açıklayabiliyorum. — Bölüm 07

☐ Açıklama yöntemlerinin hesaplama maliyetlerini karşılaştırabiliyorum. — Bölüm 08

☐ SHAP–LIME karşılaştırma deneyini tasarlayabiliyorum. — Bölüm 09

☐ Deney sonuçlarından bilimsel olarak savunulabilir çıkarımlar yapabiliyorum. — Bölüm 10

B aşamasında sunum yapısı

A aşamasında öğrendiğimiz içeriği aşağıdaki gibi yaklaşık 24 slaytlık akademik sunuma dönüştürebiliriz.

Slaytlar	İçerik
1–3	Problem, motivasyon, XAI tanımı
4–5	XAI taksonomisi ve local/global açıklamalar
6–8	LIME algoritması ve matematiği
9–12	SHAP, Shapley değerleri ve görseller
13–16	Fidelity, Faithfulness, Stability, Consistency
17–18	Sınırlılıklar ve hesaplama maliyeti
19–22	Python deneyleri ve karşılaştırmalı sonuçlar
23–24	Tartışma, sonuç ve kaynakça

Bu dağılımda özellikle 13–22. slaytlar, konunun yalnızca açıklanabilirlik değil, açıklama yöntemlerinin değerlendirilmesi olduğunu göstermemizi sağlayacak.

Akademik kaynak kitaplığı

Kitapçık ve ileride hazırlayacağımız sunum için öncelikle aşağıdaki çalışmaları temel almanı öneriyorum.

1. Ribeiro, Singh & Guestrin (2016) — “Why Should I Trust You?”: Explaining the Predictions of Any Classifier. https://doi.org/10.1145/2939672.2939778

2. Lundberg & Lee (2017) — A Unified Approach to Interpreting Model Predictions. https://proceedings.neurips.cc/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html

3. Hedström et al. (2023) — Quantus: An Explainable AI Toolkit for Responsible Evaluation of Neural Network Explanations and Beyond. https://www.jmlr.org/papers/v24/22-0142.html

4. Adebayo et al. (2018) — Sanity Checks for Saliency Maps. https://proceedings.neurips.cc/paper/8160-sanity-checks-for-saliency-maps.pdf

5. Christoph Molnar — Interpretable Machine Learning. https://christophm.github.io/interpretable-ml-book/

A aşamasının beklenen çıktısı

Bu hazırlık sonunda konuyu üç farklı düzeyde anlatabilecek durumda olmalısın: algoritmaların nasıl çalıştığı, açıklamaların hangi matematiksel özelliklere sahip olduğu ve bu açıklamaların güvenilirliğinin deneysel olarak nasıl test edilebileceği.

Önerdiğim akademik tez cümlesi:

> Açıklanabilir yapay zekâ yöntemlerinin değerlendirilmesi, yalnızca yorumlanabilir açıklamalar üretmekle sınırlı değildir; açıklamaların model davranışına sadakati, kararlılığı, tutarlılığı, hesaplama maliyeti ve kullanım bağlamındaki geçerliliği birlikte incelenmelidir.

Bir sonraki aşamada bu kitapçığı temel alarak her slayt için teknik içerik, matematiksel formüller, grafikler, konuşmacı notları ve Python deney çıktıları hazırlamak en doğru ilerleme olacaktır.